

多次元特徴量データに対する複合ネットワークモデルの構築とその有効性

Construction and Effectiveness of Composite Network Models for Multidimensional Feature Data

井上直哉¹
Naoya Inoue¹

1. はじめに

近年の計算パワーの進展とデータの拡大によって、深層学習の技術の進展は著しいものとなっている^[1]。現に、2014年以降のAI関連発明に関する特許の出願状況^[2]は、図1のようになっている。図1より、2014年以降から「深層学習に言及するAI関連発明」の出願件数は急増し、2017年以降では「AI関連発明」のうち、「深層学習に言及するAI関連開発」が約4割から5割を占めていることが読み取れる。しかし、今日の社会に存在する複雑なタスクの解決には、特定のタスクに特化した既存のネットワークモデル単体では困難である。その解決方法として、複数のネットワークモデルを用いて、各ネットワークモデルの得意とする特徴量の抽出を組み合わせることで、複雑なタスクの解決が期待できる。

本実験では、複数のネットワークモデルの組み合わせによって一つのモデルを作成し、簡易的な時間的変化を持つ画像群に対する推測の学習を行い、モデルの評価を行う。

2. 実験方法

本実験では、2つの数字画像の前後関係から、等差数列となるような3つ目の数字を推測するモデルを作成する。図2のような、画像データとそれに対する正解ラベルによって学習を行った後、テストデータによるモデルの評価を行う。

今回の実験では、MNISTの手書き数字画像70000枚を使用する。このとき元の70000枚と70000枚の並びを変更したものを用意し、2枚の組み合わせを70000通り準備し、これを使用データセットとする。この中から60000枚を学習データとし、10000枚を評価用のテストデータとして扱う。また、学習データのうち、7割の42000枚を学習に使用するデータとし、残りの18000枚を学習過程の検証用データとして扱う。

作成したモデルの概要について図3に示す。画像としての特徴量を抽出するための畳み込みニューラルネットワーク(Convolutional Neural Network: CNN)、2つの画像の前後としての時間特徴量を抽出するための長・短期記憶(Long Short Term Memory: LSTM)ネットワークを組み合わせ、softmax出力によって、2つの画像に対する正解ラベルを推測する。学習時のハイパーパラメータについて表1に示す。

表1 学習時のハイパーパラメータ

batch size	epoch	loss	optimizer
128	100	crossentropy	sgd(lr=0.01)




図1 深層学習に言及するAI関連発明の出願件数の推移




図2 使用データの概要

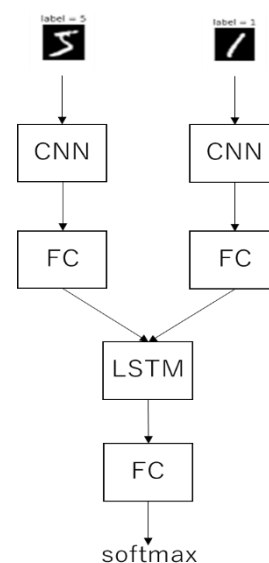


図3 作成したモデルの概要

また、学習過程と学習させたモデルの評価には、学習過程の学習データ・検証データの精度の変移、テストデータに対する精度を使用する。

3. 実験結果・考察

図4に、学習過程における学習データと検証データの精度の変移を示す。100epoch時点での精度は、学習データ・検証データともに約95%となっており、2種類のデータに対し、同等の精度を得られたことから、CNN2つとLSTMの組み合わせによる複雑なネットワークに対し、過学習をせずに正しく学習が行えていると考える。

表2に、テストデータに対する精度を示す。学習データ・検証データの約95%と同等である94.9%の精度を得られたことから、本実験で作成した学習モデルの汎化性能を確認できたと考える。

4. 今後の展望

今後の展望として、画像特徴量と時間特徴量の2つの特徴量を合わせ持つデータに依存するタスクに対し、複数のネットワークモデルを統合した一つのネットワークモデルを生成し、正常に学習できることを確認できたため、一つの画像に対し、CNN以外で抽出可能な特徴量を、元の画像と並列にモデルへ入力することで、より高い精度を得ることが可能であるかを検証する。

また、本実験ではMNISTデータセットによる等差数列の予測を行ったが、今後は、より抽象的な解を持ち、複雑なタスクの解決を目指す。本実験で作成したネットワークモデル、または本実験で作成したネットワークモデルをさらに多入力としたモデルが、そのようなタスクに対して有効であるか、どのような特徴量をモデルへの入力とした場合に变化するかを比較、評価する。

5. まとめ

本実験では、複数の種類の特徴量を持つデータに依存するタスクに対し、特定の特徴量に特化した既存のネットワークモデルを組み合わせ、一つのネットワークモデルとして作成した。その後、モデルが正しく学習が行われるか、汎化性能を有したモデルとして学習を行えたかの確認を行った。また、本実験による複合モデルの動作確認ができたことから、今後、より複雑かつ、抽象的な解を持つタスクに対し、入力する特徴量や、ネットワークモデルの複合構造によって、タスク解決が可能であるか、より高い精度を得ることができるかの検討を行う。

6. 参考文献

- [1] 松尾豊：「ディープラーニングと進化」，人工知能学会全国大会論文集，第31回，pp.1-4，2017
- [2] 特許庁：「AI関連発明の出願状況調査 報告書」，2021

Appendix

卒研：二次元画像特徴量による対象領域推定アルゴリズムの検討

学術：ドライブレコーダデータに対する画像特徴量を用いたヒヤリハット危険度推定（予定）




図4 学習過程の精度変移

表2 テストデータに対する accuracy

	accuracy
test data	0.949